GLM - Partie theorique :

Anya Levêque & Amadou Bocoum

16-10-2025

Contents

1 Introduction **1**

2 Modèle logit **2**

2.1 Fonction de vraisemblance 2

2.2 Vecteur score et information de Fisher 3

2.3 Algorithme de Newton–Raphson 4

2.4 Tests d'ajustement et diagnostics 4

3 Modèle Probit **5**

3.1 Fonction de vraisemblance 5

3.2 Vecteur score et information de Fisher 6

3.3 Algorithme de Newton–Raphson 7

3.4 Tests d'ajustement et diagnostics 8

4 Modèle complémentaire log-log (c-log-log) **9**

4.1 Fonction de vraisemblance 9

4.2 Score et information de Fisher 9

4.3 Algorithme de Newton–Raphson 12

4.4 Tests d'ajustement et diagnostics 13

1 Introduction

Dans le cadre de ce projet, nous étudions la **mortalité de scarabées** exposés à différentes doses d'un insecticide.
Pour chaque dose X_i, on observe Y_i scarabées morts parmi n_i individus.

Notre objectif est de **modéliser la probabilité de décès** p_i en fonction de la dose, à l'aide de plusieurs modèles de régression binomiale :

- le modèle **logistique (lien logit)**,
- le modèle **probit**,
- et le modèle **complémentaire log-log (c-log-log)**.

2 Modèle logit

On suppose que le nombre de scarabées morts Y_i à la dose X_i suit une loi binomiale :

$$Y_i \sim \text{Bin}(n_i, p_i)$$

où : - n_i est le nombre total d'individus exposés,
- p_i la probabilité de décès à la dose X_i.

La relation entre p_i et X_i est donnée par la **fonction de lien logistique** :

$\log\left(\frac{p_i}{1-p_i}\right) = \eta_i = x_i^\top \beta = \beta_0 + \beta_1 X_i$.

On a donc: $\log\left(\frac{p_i}{1-p_i}\right) = \eta_i \quad \iff \quad p_i = \frac{1}{1+e^{-\eta_i}}$

où : - η_i est la variable linéaire , - β_0 et β_1 sont des paramètres inconnus à estimer.

Cette fonction permet de relier une probabilité $p_i \in (0,1)$ à une combinaison linéaire des variables explicatives (ici, la dose X_i).

2.1 Fonction de vraisemblance

Chaque observation suit une loi binomiale :

$$\Pr(Y_i = y_i) = \binom{n_i}{y_i} p_i^{y_i} (1-p_i)^{n_i - y_i}.$$

En supposant l'indépendance des observations, la **vraisemblance du modèle** est le produit :

$$L(\beta) = \prod_{i=1}^{m} \binom{n_i}{y_i} p_i^{y_i} (1-p_i)^{n_i - y_i}.$$

On peut ignorer la constante $\binom{n_i}{y_i}$

La **log-vraisemblance** :

$$\ell(\beta) = \sum_{i=1}^{m} \left[y_i \log(p_i) + (n_i - y_i) \log(1-p_i) \right].$$

$\ell(\beta) = \sum_{i=1}^{m} \left[y_i \, \log\left(\frac{p_i}{1-p_i}\right) + n_i \, \log\left(\frac{1}{1+e^{\eta_i}}\right) \right]$. .

Or, $\eta_i = \log\left(\frac{p_i}{1-p_i}\right)$ donc

$$\ell(\beta) = \sum_{i=1}^{m} \left[y_i \eta_i - n_i \log(1+e^{\eta_i}) \right].$$

2.2 Vecteur score et information de Fisher

$$U(\beta) \;=\; \frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^{m} \left[y_i \, \frac{\partial \eta_i}{\partial \beta} \;-\; n_i \, \frac{\partial \log(1+e^{\eta_i})}{\partial \beta} \right].$$

Or

$$\frac{\partial \log(1+e^{\eta_i})}{\partial \beta} = \frac{e^{\eta_i}}{1+e^{\eta_i}} \, x_i = p_i \, x_i, \qquad \frac{\partial \eta_i}{\partial \beta} = x_i,$$

d'où

$$U(\beta) = \sum_{i=1}^{m} \Big(y_i \, x_i - n_i \, p_i \, x_i \Big) = \sum_{i=1}^{m} x_i \, (y_i - n_i p_i).$$

$$\boxed{U(\beta) \;=\; X^\top (y - \mu)}$$

avec

$$p_i = \frac{1}{1+e^{-\eta_i}}, \quad \eta_i = x_i^\top \beta, \qquad \mu_i = n_i \, p_i.$$

La **matrice d'information de Fisher** mesure la *quantité d'information* contenue dans les données sur les paramètres : L'information de fisher est l'esperance negative de la derivée de la fonction score:

Hessien (dérivée du score).

$$\frac{\partial U(\beta)}{\partial \beta^\top} = \sum_{i=1}^{m} x_i \left(-n_i \, \frac{\partial p_i}{\partial \beta^\top} \right)$$

Par la règle de chaîne :

$$\frac{\partial p_i}{\partial \beta} = \frac{\partial p_i}{\partial \eta_i} \, \frac{\partial \eta_i}{\partial \beta}, \qquad \frac{\partial \eta_i}{\partial \beta} = x_i,$$

et, pour le logit,

$$\frac{\partial p_i}{\partial \eta_i} = \frac{e^{\eta_i}}{(1+e^{\eta_i})^2} = p_i(1-p_i).$$

Donc

$$\boxed{\frac{\partial p_i}{\partial \beta} = p_i(1-p_i) \, x_i}.$$

Hessien (dérivée du score).

$$\frac{\partial U(\beta)}{\partial \beta^\top} = \sum_{i=1}^{m} x_i \left(-n_i \, \frac{\partial p_i}{\partial \beta^\top} \right) = -\sum_{i=1}^{m} n_i \, p_i (1-p_i) \, x_i x_i^\top.$$

Information de Fisher .

$$\boxed{\mathcal{I}(\beta) = -\mathbb{E}\left[\frac{\partial U(\beta)}{\partial \beta^\top} \right] = \sum_{i=1}^{m} n_i \, p_i (1-p_i) \, x_i x_i^\top = X^\top W X, \quad W = \operatorname{diag}(n_i p_i (1-p_i))}.$$

2.3 Algorithme de Newton–Raphson

L'algorithme de Newton–Raphson permet d'estimer le vecteur de paramètres β en maximisant la log-vraisemblance $\ell(\beta)$.

L'itération générale est donnée par :

$$\beta^{(m+1)} = \beta^{(m)} + [\mathcal{J}(\beta^{(m)})]^{-1} U(\beta^{(m)}),$$

où : - $U(\beta)$ est la fonction score : $U(\beta) = X^\top (y - \mu)$, - $\mathcal{J}(\beta)$ est la matrice d'information de Fisher : $\mathcal{J}(\beta) = X^\top W X$.

En remplaçant ces expressions, on obtient :

$$\boxed{\beta^{(m+1)} = \beta^{(m)} + (X^\top W^{(m)} X)^{-1} X^\top (y - \mu^{(m)}),}$$

avec :

$$W^{(m)} = \mathrm{diag}(n_i\, p_i^{(m)}(1 - p_i^{(m)})), \qquad \mu^{(m)} = n_i\, p_i^{(m)}, \qquad p_i^{(m)} = \frac{1}{1 + e^{-\eta_i^{(m)}}}, \quad \eta_i^{(m)} = x_i^\top \beta^{(m)}.$$

L'algorithme est initialisé avec $\beta^{(0)} = (0,\, 0)^\top$ et s'arrête lorsque la variation des paramètres devient négligeable :

$$\|\beta^{(m+1)} - \beta^{(m)}\| < \varepsilon,$$

où ε est une tolérance numérique fixée (par exemple 10^{-6}) .

2.4 Tests d'ajustement et diagnostics

2.4.1 Deviance

$$D = 2[\ell_{\text{saturé}} - \ell_{\text{GLM}}(\hat{\beta})] = 2 \sum_{i=1}^{m} \left[y_i \log \frac{y_i}{n_i \hat{p}_i} + (n_i - y_i) \log \frac{n_i - y_i}{n_i (1 - \hat{p}_i)} \right].$$

Une petite déviance indique un bon ajustement.

2.4.2 Statistique du χ^2 de Pearson

$$X^2 = \sum_{i=1}^{m} \frac{(y_i - \hat{\mu}_i)^2}{n_i \hat{p}_i (1 - \hat{p}_i)}.$$

Si le modèle est correct, X^2 suit approximativement une loi du χ^2 avec $m - k$ degrés de liberté (k = nombre de paramètres).

2.4.3 (c) Résidus

Les **résidus de déviance** et **de Pearson** mesurent les écarts individuels :

$$r_{D,i} = \mathrm{sign}(y_i - \hat{\mu}_i) \sqrt{2 \left[y_i \log \frac{y_i}{\hat{\mu}_i} + (n_i - y_i) \log \frac{n_i - y_i}{n_i - \hat{\mu}_i} \right]},$$

$$r_{P,i} = \frac{y_i - \hat{\mu}_i}{\sqrt{n_i \hat{p}_i (1 - \hat{p}_i)}}.$$

3 Modèle Probit

On suppose que le nombre de scarabées morts Y_i à la dose X_i suit une loi binomiale :

$$Y_i \sim \text{Bin}(n_i, p_i)$$

où : - n_i est le nombre total d'individus exposés,
- p_i est la probabilité de décès à la dose X_i.

La relation entre p_i et X_i est donnée par la **fonction de lien probit** :

$$\Phi^{-1}(p_i) = \eta_i = x_i^\top \beta = \beta_0 + \beta_1 X_i,$$

où : - $\Phi^{-1}(\cdot)$ est la fonction quantile (inverse de la fonction de répartition) de la loi normale standard,
- η_i est la variable linéaire,
- β_0 et β_1 sont des paramètres inconnus à estimer.

En inversant le lien, on obtient la probabilité prédite :

$$p_i = \Phi(\eta_i) = \Phi(\beta_0 + \beta_1 X_i),$$

où $\Phi(\cdot)$ désigne la fonction de répartition de la loi normale centrée réduite.

3.1 Fonction de vraisemblance

Chaque observation suit une loi binomiale :

$$\Pr(Y_i = y_i) = \binom{n_i}{y_i} p_i^{y_i} (1 - p_i)^{n_i - y_i}.$$

En supposant l'indépendance des observations, la **vraisemblance du modèle** est le produit :

$$L(\beta) = \prod_{i=1}^{m} \binom{n_i}{y_i} [\Phi(\eta_i)]^{y_i} [1 - \Phi(\eta_i)]^{n_i - y_i},$$

où $\Phi(\cdot)$ est la fonction de répartition de la loi normale centrée réduite.

La **log-vraisemblance** s'écrit alors : (On peut ignorer la constante $\binom{n_i}{y_i}$)

$$\ell(\beta) = \log L(\beta) = \sum_{i=1}^{m} \left[y_i \log(\Phi(\eta_i)) + (n_i - y_i) \log(1 - \Phi(\eta_i)) \right].$$

3.2 Vecteur score et information de Fisher

3.2.1 Vecteur score

On dérive la log-vraisemblance par rapport à β.
On sait que :

$$\frac{\partial \Phi(\eta_i)}{\partial \eta_i} = \phi(\eta_i),$$

où $\phi(\eta_i)$ désigne la densité de la loi normale standard :

$$\phi(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right).$$

Ainsi :

$$\frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^{m} \left[\frac{y_i\,\phi(\eta_i)}{\Phi(\eta_i)} - \frac{(n_i - y_i)\,\phi(\eta_i)}{1-\Phi(\eta_i)}\right] x_i.$$

En posant $p_i = \Phi(\eta_i)$, on obtient :

$$\frac{\partial \ell(\beta)}{\partial \beta} = \sum_i \phi(\eta_i) x_i \left[\frac{y_i}{p_i} - \frac{n_i - y_i}{1-p_i}\right] = \sum_i \phi(\eta_i) x_i \frac{y_i - n_i p_i}{p_i(1-p_i)}.$$

On en déduit la forme compacte du vecteur score :

$$\boxed{U(\beta) = \sum_{i=1}^{m} x_i\,\phi(\eta_i)\,\frac{y_i - n_i p_i}{p_i(1-p_i)}.}$$

En posant $\mu = n_i p_i$, on obtient sous forme matricielle:

$$\boxed{U(\beta) = X^\top D(\beta)\,(y-\mu), \qquad D(\beta) = \operatorname{diag}\left(\frac{\phi(\eta_i)}{p_i(1-p_i)}\right).}$$

3.2.2 Information de Fisher

L'information de Fisher est l'espérance négative de la dérivée du score :

$$\mathcal{J}(\beta) = -\,\mathbb{E}\left[\frac{\partial U(\beta)}{\partial \beta^\top}\right].$$

Pour un modèle binomial, on a $\mathcal{J}(\beta) = X^\top W(\beta)\,X$, où X est la matrice de design (empilement des $x_i^\top$) et $W(\beta)$ est la matrice **diagonale** des poids w_i.

Pour le modèle **probit** :

On part de $p_i = \Phi(\eta_i)$, $\phi = \Phi'$, $\eta_i = x_i^\top \beta$.
La dérivée du score par rapport à η_i vaut

$$\frac{\partial^2 \ell}{\partial \eta_i^2} = -n_i \frac{dp_i}{d\eta_i} \frac{\phi(\eta_i)}{p_i(1-p_i)} \;+\; (y_i - n_i p_i)\,\frac{d}{d\eta_i}\left(\frac{\phi(\eta_i)}{p_i(1-p_i)}\right).$$

En prenant l'espérance par rapport à Y_i et en utilisant la propriété

$$\mathbb{E}[Y_i] = n_i p_i \quad \Rightarrow \quad \mathbb{E}[y_i - n_i p_i] = 0,$$

le second terme disparaît : seul le premier contribue à l'information de Fisher.

Ainsi :

$$\mathbb{E}\left[\frac{\partial^2 \ell}{\partial \eta_i^2}\right] = -n_i \, \frac{dp_i}{d\eta_i} \, \frac{\phi(\eta_i)}{p_i(1-p_i)}.$$

Or, pour le lien probit,

$$\frac{dp_i}{d\eta_i} = \phi(\eta_i),$$

d'où :

$$-\mathbb{E}\left[\frac{\partial^2 \ell}{\partial \eta_i^2}\right] = n_i \, \frac{\phi(\eta_i)^2}{p_i(1-p_i)}.$$

Pour revenir à la dérivée par rapport à β, on utilise
$\frac{\partial \eta_i}{\partial \beta} = x_i$, ce qui donne la contribution :

$$n_i \, \frac{\phi(\eta_i)^2}{p_i(1-p_i)} \, x_i x_i^\top.$$

On en déduit :

$$\boxed{\mathcal{I}(\beta) = X^\top W(\beta)\, X, \qquad W(\beta) = \operatorname{diag}\left(n_i \, \frac{\phi(\eta_i)^2}{p_i(1-p_i)} \right).}$$

3.3 Algorithme de Newton–Raphson

L'algorithme de **Newton–Raphson** permet d'estimer le vecteur de paramètres β en maximisant la log-vraisemblance $\ell(\beta)$.

L'itération générale est donnée par :

$$\beta^{(m+1)} = \beta^{(m)} + [\mathcal{I}(\beta^{(m)})]^{-1} U(\beta^{(m)}),$$

où : - $U(\beta)$ est le vecteur **score** ; - $\mathcal{I}(\beta)$ est la **matrice d'information de Fisher**.

Pour le modèle probit :

On a :

$$U(\beta) = \sum_{i=1}^{m} x_i \, \phi(\eta_i) \, \frac{y_i - n_i p_i}{p_i(1-p_i)},$$

et

$$\mathcal{I}(\beta) = X^\top W(\beta)\, X, \quad \text{avec} \quad W(\beta) = \operatorname{diag}\left(n_i \, \frac{\phi(\eta_i)^2}{p_i(1-p_i)} \right).$$

En remplaçant ces expressions dans la mise à jour de Newton–Raphson, on obtient :

$$\boxed{\beta^{(m+1)} = \beta^{(m)} + (X^\top W^{(m)} X)^{-1} X^\top D^{(m)} (y - \mu^{(m)}),}$$

avec :

$$p_i^{(m)} = \Phi(\eta_i^{(m)}), \quad \eta_i^{(m)} = x_i^\top \beta^{(m)}, \quad \phi_i^{(m)} = \phi(\eta_i^{(m)}), \quad \mu^{(m)} = n_i p_i^{(m)}, \quad D^{(m)} = \operatorname{diag}\left(\frac{\phi_i^{(m)}}{p_i^{(m)}(1-p_i^{(m)})} \right).$$

$\beta^{(0)} = (0,0)^\top$.

3.4 Tests d'ajustement et diagnostics

3.4.1 Déviance

La **déviance** mesure la perte d'information du modèle ajusté par rapport au modèle saturé (qui reproduit parfaitement les données) :

$$D = 2\left[\ell_{\text{saturé}} - \ell_{\text{GLM}}(\hat{\beta})\right] = 2\sum_{i=1}^{m}\left[y_i \log\frac{y_i}{n_i\hat{p}_i} + (n_i - y_i)\log\frac{n_i - y_i}{n_i(1-\hat{p}_i)}\right].$$

Une **petite déviance** indique un bon ajustement du modèle probit aux données.

3.4.2 Statistique du χ^2 de Pearson

La statistique du χ^2 de Pearson compare les fréquences observées et prévues :

$$X^2 = \sum_{i=1}^{m} \frac{(y_i - \hat{\mu}_i)^2}{n_i\hat{p}_i(1-\hat{p}_i)},$$

avec $\hat{\mu}_i = n_i\hat{p}_i$.

Sous l'hypothèse d'un bon ajustement du modèle, X^2 suit approximativement une loi du χ^2 à $m-k$ degrés de liberté, où k est le nombre de paramètres estimés (ici $k = 2$).

3.4.3 Résidus individuels

Les **résidus de déviance** et **de Pearson** permettent d'évaluer la qualité de l'ajustement point par point.

- **Résidu de déviance :**

$$r_{D,i} = \operatorname{sign}(y_i - \hat{\mu}_i)\sqrt{2\left[y_i \log\frac{y_i}{\hat{\mu}_i} + (n_i - y_i)\log\frac{n_i - y_i}{n_i - \hat{\mu}_i}\right]}.$$

- **Résidu de Pearson :**

$$r_{P,i} = \frac{y_i - \hat{\mu}_i}{\sqrt{n_i\hat{p}_i(1-\hat{p}_i)}}.$$

Ces deux types de résidus devraient être proches de 0 pour un modèle bien ajusté.

4 Modèle complémentaire log-log (c-log-log)

On suppose que le nombre de scarabées morts Y_i à la dose X_i suit une loi binomiale :

$$Y_i \sim \text{Bin}(n_i, p_i)$$

où : - n_i est le nombre total d'individus exposés,
- p_i la probabilité de décès à la dose X_i.

La relation entre p_i et X_i est donnée par la **fonction de lien complémentaire log-log** :

$$g^{-1}(\eta_i) = 1 - \exp[-\exp(\eta_i)], \quad \text{où } \eta_i = x_i^\top \beta.$$

On pose donc :

$$p_i = 1 - \exp[-\exp(\eta_i)].$$

4.1 Fonction de vraisemblance

Chaque observation suit une loi binomiale :

$$\Pr(Y_i = y_i) = \binom{n_i}{y_i} p_i^{y_i} (1-p_i)^{n_i - y_i}.$$

En supposant l'indépendance des observations, la **vraisemblance du modèle** est le produit :

$$L(\beta) = \prod_{i=1}^{m} \binom{n_i}{y_i} p_i^{y_i} (1-p_i)^{n_i - y_i},$$

où $p_i = 1 - e^{-\exp(\eta_i)}$.

La **log-vraisemblance** correspondante est :

$$\ell(\beta) = \log L(\beta) = \sum_{i=1}^{m} \left[\log \binom{n_i}{y_i} + y_i \log(p_i) + (n_i - y_i) \log(1-p_i) \right],$$

avec $p_i = 1 - e^{-\exp(\eta_i)}$.

4.2 Score et information de Fisher

Le **vecteur score** est donné par :

$$U(\beta) = \frac{\partial \ell(\beta)}{\partial \beta} = \sum_{i=1}^{n} \left(\frac{\partial \ell(\beta)}{\partial p_i} \cdot \frac{dp_i}{d\eta_i} \right) \frac{\partial \eta_i}{\partial \beta}.$$

On calcule séparément chaque terme :

$$\frac{\partial \ell(\beta)}{\partial p_i} = \frac{y_i}{p_i} - \frac{n_i - y_i}{1 - p_i} = \frac{y_i - n_i p_i}{p_i(1-p_i)},$$

$$\frac{dp_i}{d\eta_i} = \frac{d}{d\eta_i}\left(1 - e^{-\exp(\eta_i)}\right) = e^{-\exp(\eta_i)} \cdot e^{\eta_i} = e^{\eta_i - \exp(\eta_i)},$$

et

$$\frac{\partial \eta_i}{\partial \beta} = \frac{\partial (x_i^\top \beta)}{\partial \beta} = x_i.$$

Ainsi, on obtient :

$$U(\beta) = \sum_{i=1}^{n} \frac{y_i - n_i p_i}{p_i(1-p_i)}\, e^{\eta_i - \exp(\eta_i)}\, x_i.$$

Or, $p_i = 1 - e^{-\exp(\eta_i)}$ et donc $1 - p_i = e^{-\exp(\eta_i)}$.
En remplaçant, on peut écrire :

$$\boxed{U(\beta) = \sum_{i=1}^{n} \frac{y_i - n_i p_i}{p_i e^{-\exp(\eta_i)}}\, e^{\eta_i - \exp(\eta_i)}\, x_i = \sum_{i=1}^{n} (y_i - n_i p_i)\, \frac{e^{\eta_i}}{p_i}\, x_i.}$$

Remarque. On peut réécrire le facteur $\dfrac{e^{\eta_i}}{p_i}$ sous la forme utilisée dans le code. On a en effet, pour le lien complémentaire log-log,

$$p_i = 1 - e^{-e^{\eta_i}}, \qquad 1 - p_i = e^{-e^{\eta_i}}, \qquad \frac{dp_i}{d\eta_i} = e^{\eta_i - e^{\eta_i}}.$$

Donc

$$\frac{dp_i/d\eta_i}{p_i(1-p_i)} = \frac{e^{\eta_i - e^{\eta_i}}}{p_i e^{-e^{\eta_i}}} = \frac{e^{\eta_i}}{p_i}.$$

On retrouve ainsi la forme standard des GLM :

$$U(\beta) = \sum_{i=1}^{n} x_i\, (y_i - n_i p_i)\, \frac{dp_i/d\eta_i}{p_i(1-p_i)} = X^\top D(\beta)\, (y - \mu),$$

avec

$$D(\beta) = \operatorname{diag}\left(\frac{dp_i/d\eta_i}{p_i(1-p_i)} \right), \qquad \mu_i = n_i p_i.$$

C'est cette écriture qui est implémentée dans notre partie pratique (code R).

4.2.1 Information de Fisher

$$I(\beta) = \mathrm{Cov}(U(\beta)) = \mathrm{Var}(U(\beta)).$$

On a vu que :

$$U(\beta) = \sum_{i=1}^{n} x_i(y_i - n_i p_i)\frac{e^{\eta_i}}{p_i}.$$

On note alors :

$$s_i = x_i(y_i - n_i p_i)\frac{e^{\eta_i}}{p_i}.$$

Comme les observations sont indépendantes :

$$I(\beta) = \sum_{i=1}^{n} \mathrm{Var}(s_i).$$

Or :

$$\mathrm{Var}(s_i) = x_i x_i^\top \mathrm{Var}(y_i - n_i p_i)\left(\frac{e^{\eta_i}}{p_i}\right)^2 = x_i x_i^\top \mathrm{Var}(y_i)\frac{e^{2\eta_i}}{p_i^2}.$$

Puisque $Y_i \sim \mathcal{B}(n_i, p_i)$,

$$\mathrm{Var}(Y_i) = n_i p_i(1 - p_i).$$

Ainsi :

$$\mathrm{Var}(s_i) = x_i x_i^\top n_i p_i(1 - p_i)\frac{e^{2\eta_i}}{p_i^2}.$$

Comme $1 - p_i = e^{-\exp(\eta_i)}$, on obtient :

$$\mathrm{Var}(s_i) = x_i x_i^\top n_i \frac{e^{2\eta_i - \exp(\eta_i)}}{p_i}.$$

Finalement :

$$\boxed{I(\beta) = \sum_{i=1}^{n} x_i x_i^\top n_i \frac{e^{2\eta_i - \exp(\eta_i)}}{p_i}.}$$

Remarque. On peut écrire cette expression sous la forme matricielle classique des GLM. On pose

$$w_i = n_i \frac{e^{2\eta_i - e^{\eta_i}}}{p_i}.$$

En utilisant $\frac{dp_i}{d\eta_i} = e^{\eta_i - e^{\eta_i}}$ et $1 - p_i = e^{-e^{\eta_i}}$, on vérifie que

$$w_i = n_i \frac{(dp_i/d\eta_i)^2}{p_i(1 - p_i)}.$$

Ainsi,

$$\mathcal{J}(\beta) = \sum_{i=1}^{n} x_i x_i^\top w_i = X^\top W(\beta)\, X,$$

avec

$$W(\beta) = \text{diag}(w_i) = \text{diag}\left(n_i \, \frac{(dp_i/d\eta_i)^2}{p_i(1-p_i)} \right).$$

C'est cette matrice de poids $W(\beta)$ qui est utilisée dans notre algorithme de Newton–Raphson codé en R (dans la partie pratique).

4.3 Algorithme de Newton–Raphson

L'algorithme de Newton–Raphson permet d'obtenir les estimateurs du maximum de vraisemblance en itérant selon :

$$\beta^{(m+1)} = \beta^{(m)} + \left[I(\beta^{(m)}) \right]^{-1} U(\beta^{(m)}),$$

où $U(\beta^{(m)})$ est le vecteur score évalué à l'itération m :

$$U(\beta^{(m)}) = \sum_{i=1}^{n} x_i \Big[y_i - n_i(1 - e^{-\exp(x_i^\top \beta^{(m)})}) \Big] \frac{e^{x_i^\top \beta^{(m)}}}{p_i^{(m)}}.$$

avec $p_i^{(m)} = 1 - e^{-\exp(x_i^\top \beta^{(m)})}$.

et

$$I(\beta^{(m)}) = \sum_{i=1}^{n} x_i x_i^\top \, n_i \, \frac{e^{2x_i^\top \beta^{(m)} - e^{x_i^\top \beta^{(m)}}}}{1 - e^{-e^{x_i^\top \beta^{(m)}}}}.$$

On a les **proportions observées** :

$$\tilde{p}_i = \frac{y_i}{n_i}.$$

Le **lien du modèle** est :

$$\log[-\log(1 - p_i)] = \eta_i.$$

D'où :

$$\eta_i^0 = g(\tilde{p}_i) = \log[-\log(1 - \tilde{p}_i)].$$

Dans le modèle, on a :

$$\eta_i = x_i^\top \beta.$$

En remplaçant η_i par les valeurs approchées η_i^0, on obtient :

$$\eta_i^0 \approx X\beta^0,$$

et donc :

$$\boxed{\beta^0 = (X^\top X)^{-1} X^\top \eta^0,}$$

avec :

$$\eta^0 = \left[\log[-\log(1 - \tilde{p}_i)] \right]_{i=1,\ldots,n}.$$

Remarque: Dans notre partie pratique, nous choisissons d'initialiser simplement par (0,0).

4.4 Tests d'ajustement et diagnostics

4.4.1 Déviance

La **déviance** mesure la perte d'information du modèle ajusté par rapport au modèle saturé (qui reproduit parfaitement les données) :

$$D = 2\,[\ell_{\text{saturé}} - \ell_{\text{GLM}}(\hat{\beta})].$$

Le modèle saturé correspond à $p_i = \dfrac{y_i}{n_i}$.

$$\ell_{\text{saturé}} = \sum_{i=1}^{n} \left[\log \binom{n_i}{y_i} + y_i \log\left(\frac{y_i}{n_i}\right) + (n_i - y_i) \log\left(1 - \frac{y_i}{n_i}\right) \right].$$

Ainsi :

$$D = 2 \sum_{i=1}^{n} \left[y_i \log \frac{(y_i/n_i)}{\widehat{p}_i} + (n_i - y_i) \log \frac{1 - (y_i/n_i)}{1 - \widehat{p}_i} \right].$$

$$D = 2 \sum_{i=1}^{n} \left[y_i \log \frac{y_i}{n_i \widehat{p}_i} + (n_i - y_i) \log \frac{n_i - y_i}{n_i(1 - \widehat{p}_i)} \right].$$

Une **petite déviance** indique un bon ajustement du modèle (ici, le modèle complémentaire log-log).

4.4.2 Statistique du χ^2 de Pearson

La statistique du χ^2 de Pearson compare les fréquences observées et prévues :

$$X^2 = \sum_{i=1}^{n} \frac{(y_i - n_i \widehat{p}_i)^2}{n_i \widehat{p}_i (1 - \widehat{p}_i)}.$$

Sous l'hypothèse d'un bon ajustement du modèle, X^2 suit approximativement une loi du χ^2 à $n-k$ degrés de liberté, où k est le nombre de paramètres estimés (ici $k = 2$).

4.4.3 Résidus individuels

Les **résidus de déviance** et **de Pearson** permettent d'analyser les écarts observation par observation.

- **Résidu de déviance :**

$$d_i = \text{sign}(y_i - n_i \widehat{p}_i) \sqrt{2 \left[y_i \log \frac{y_i}{n_i \widehat{p}_i} + (n_i - y_i) \log \frac{n_i - y_i}{n_i(1 - \widehat{p}_i)} \right]}.$$

avec :

$$\sum_{i=1}^{n} d_i^2 = D.$$

- **Résidu de Pearson :**

$$r_i = \frac{y_i - n_i \hat{p}_i}{\sqrt{n_i \hat{p}_i (1 - \hat{p}_i)}},$$

avec :

$$\sum_{i=1}^{n} r_i^2 = X^2.$$